Roteiro de Arguição Técnica: Projetos de Regressão

Projeto: Oráculo Preditivo de Preços de Veículos (Car Price Prediction)

Grupo: Gustavo Molina, João Emanoel, Milton Wagner e Murilo.

PARTE 1: Abertura e Descrição do Dataset (O que analisamos, Linhas e Colunas)

Trabalhamos com o dataset Car Price Prediction (Vehicle dataset from CarDekho, do Kaggle), que traz preços de carros e motos usados do **mercado indiano**. Os preços estão em **lakhs de rupias** (1 lakh = ₹100.000) e os dados são de cerca de 2018.

- **Volumetria:** o dataset bruto tem **301 linhas e 9 colunas** (Car_Name, Year, Selling_Price, Present_Price, Kms_Driven, Fuel_Type, Seller_Type, Transmission e Owner). Não havia valores nulos. Havia 2 duplicatas, removidas, restando 299 linhas. O arquivo mistura **198 carros e 101 motos**, e os modelos foram treinados só com os carros.
- **Divisão dos dados (rigor metodológico):** dividimos os 198 carros em **158 para treino** (80%) e **40 para teste** (20%), com random_state=42. O conjunto de teste ficou fora de todo o ajuste de hiperparâmetros, para avaliar os modelos em dados inéditos.
- **Variável alvo (target):** o preço de venda (Selling_Price).
- **Variáveis preditoras (features):** preço do carro novo (Present_Price), quilometragem (Kms_Driven), número de proprietários (Owner), a feature derivada idade do carro (Car_Age = 2019 − Year) e as categóricas combustível (Fuel_Type), tipo de vendedor (Seller_Type) e transmissão (Transmission). O ano (Year) é usado apenas para derivar a idade.

PARTE 2: O que foi descartado e a Análise Exploratória (EDA)

- **O que foi descartado:** (a) o nome do modelo (Car_Name) não foi usado como feature: transformá-lo em colunas geraria dimensionalidade excessiva e esparsa no One-Hot Encoding, sem poder preditivo adicional ao do preço do carro novo (Present_Price), que já resume o valor de mercado base. Ele serviu apenas para padronizar os nomes e identificar o tipo de veículo. (b) As **101 motos** foram excluídas dos modelos, porque o preço médio de venda delas (0,64 lakh) é muito diferente do dos carros (6,60 lakh). A separação usa uma expressão regular de marcas de moto, uma heurística que não foi validada linha a linha. (c) As 2 duplicatas exatas.
- **Sobre a EDA:** a matriz de correlação (carros) mostra que o preço do carro novo tem correlação de **+0,82** com o preço de venda; a idade tem −0,35, a quilometragem −0,11 e o número de proprietários −0,08. A distribuição do alvo tem forte **assimetria à direita** (skew de 2,7), com uma cauda longa de carros caros.
- **Outliers:** pela regra de 1,5 × IQR há 16 outliers em Selling_Price, 11 em Present_Price e 6 em Kms_Driven, todos na cauda superior. **Decidimos mantê-los**, porque são carros reais (como o Land Cruiser 2010, novo a 92,60 lakh e vendido a

35,00 lakh). Essa decisão tem um custo: esse único carro domina o erro do conjunto de teste (Parte 4).

PARTE 3: A Escolha das Curvas e a Análise do Tempo de Processamento

Na visualização de performance, usamos gráficos de dispersão de **valores reais contra valores preditos** para os três modelos, com a linha de referência de 45° (y = x):

- **Leitura das curvas:** até cerca de 15 lakh os três modelos ficam próximos da diagonal. Acima disso o erro cresce, e nenhum modelo é confiável acima de ≈15–20 lakh. Para o Land Cruiser (real 35 lakh), a previsão foi 48,96 na RLM, 19,60 no RFR e 12,11 no SVR. Sem esse carro, RFR e SVR erram cerca de 30% menos que a RLM (MAE de 0,756 contra 1,073).
- **Houve problema de tempo de processamento?** não medimos os tempos de forma sistemática. Com apenas 158 carros no treino, o treino e a predição foram rápidos na nossa execução (observação, não medição). Por isso, **nenhum modelo foi descartado por lentidão**. Os critérios de escolha foram de desempenho analítico:

1. Regressão Linear Múltipla (RLM): teve o melhor R^2 de teste (0,799) e o menor RMSE (2,605), mas esse resultado depende do Land Cruiser: sem ele, é o pior dos três (R^2 de 0,849 contra 0,908 do RFR e 0,934 do SVR). Tem o maior MAPE (24,5%), superestima o carro mais caro e chegou a prever um preço negativo (−0,17 lakh).

2. SVR: teve o pior R^2 de teste (0,587) e o maior RMSE (3,733), o maior sinal de overfitting (R^2 de treino de 0,974, gap de 0,387) e a maior instabilidade na validação cruzada (±0,150). É sensível aos hiperparâmetros do kernel RBF, e o melhor C (300) é o maior valor da grade.

3. Random Forest (RFR): teve o menor MAE de teste (1,122 lakh), o menor MAPE (16,1%) e o maior R^2 de validação cruzada (0,869). Não é o melhor em R^2 de teste (0,790) e tem overfitting moderado (gap de 0,202). Por isso o recomendamos como **apoio à precificação**, e não como um modelo sem limitações.

PARTE 4: Defesa Técnica das Perguntas da Arguição (Domínio Teórico e Métricas)

1. Eixo: Tratamento de Dados e Premissas Estatísticas

Fundamentação: Teorema de Gauss-Markov e Sensibilidade de Algoritmos baseados em Distância.

- **Pergunta:** *Para a Regressão Linear, vocês verificaram a Multicolinearidade entre as variáveis independentes? Como a presença de variáveis altamente correlacionadas afeta os coeficientes do modelo?*
    - **Resposta:** Sim. Calculamos o VIF das quatro variáveis numéricas: Present_Price 1,10, Kms_Driven 2,23, Owner 1,04 e Car_Age 2,07, todos baixos (as dummies não entraram no cálculo). A maior correlação entre preditoras é entre quilometragem e idade (+0,71), o que é esperado, mas não é problemática. É preciso diferenciar a correlação entre preditora e alvo da multicolinearidade: a correlação de +0,82 entre Present_Price e Selling_Price é desejável e não é multicolinearidade, que é a correlação entre as próprias

preditoras. Quando ela é forte, os coeficientes da regressão linear ficam instáveis (variância inflada, podendo até trocar de sinal) e a interpretação individual se prejudica, embora a previsão total possa continuar boa. No nosso caso, a quilometragem tem coeficiente grande na RLM (−1,158) apesar da correlação simples de só −0,11, porque o modelo a controla pelo preço novo e pela idade.

- **Pergunta:** *O SVR e a Regressão Linear são sensíveis à escala dos dados. Qual técnica de normalização ou padronização foi utilizada e por que isso é crítico especificamente para o funcionamento do Kernel no SVR?*
    - **Resposta:** Usamos o StandardScaler (média zero e desvio padrão um), dentro do Pipeline e ajustado só nos dados de treino, para não haver vazamento. Aplicamos apenas à RLM e ao SVR; o Random Forest não precisa de escala, porque divide por limiares. No SVR com kernel RBF, o kernel depende da distância entre os pontos. Sem padronizar, a quilometragem (dezenas de milhares) dominaria o cálculo frente ao número de proprietários (0 a 3), e o parâmetro gamma perderia sentido. Na RLM sem regularização, a escala não altera as previsões, mas permite comparar a magnitude dos coeficientes. Escolhemos a padronização e não o MinMaxScaler porque mantivemos os outliers, e o MinMax comprimiria a maior parte dos dados numa faixa estreita por causa de valores extremos (como o preço novo de 92,6 lakh). Não chegamos a testar o MinMaxScaler.
- **Pergunta:** *Como o grupo lidou com Outliers? Baseado na fundamentação teórica, qual dos três algoritmos escolhidos é inerentemente mais robusto a valores discrepantes e por quê?*
    - **Resposta:** Identificamos os outliers pela regra de 1,5 × IQR (16 em Selling_Price, 11 em Present_Price e 6 em Kms_Driven, todos na cauda superior) e decidimos mantê-los, porque são carros reais; removê-los deixaria o modelo cego para os carros caros. Na teoria, o Random Forest é o mais robusto a valores extremos nas variáveis de entrada, pois suas árvores dividem por limiares e a previsão é a média de folhas, sem depender de distâncias. A RLM é a mais sensível, porque minimiza o erro quadrático. O SVR com kernel RBF depende de distâncias. Na prática, o Land Cruiser mostrou o efeito: a RLM o previu em 48,96 (real 35), e RFR e SVR ficaram abaixo (19,60 e 12,11). Nossa hipótese, que não testamos, é que a RLM extrapola em linha reta e as árvores não extrapolam além do treino. Ou seja, robustez não significa acertar o outlier: nenhum modelo foi confiável acima de ≈15–20 lakh.

2. Eixo: Complexidade e Arquitetura dos Modelos

Fundamentação: Trade-off Viés-Variância (Bias-Variance Tradeoff).

- **Pergunta:** *O Random Forest é um método de Ensemble (Bagging). Como a profundidade das árvores e o número de estimadores influenciam no risco de Overfitting neste projeto?*
    - **Resposta:** O n_estimators define quantas árvores entram na média. No bagging, aumentar o número de árvores reduz a variância e estabiliza as previsões sem aumentar o overfitting, ao custo de mais computação. Já a profundidade (max_depth) e o tamanho mínimo da folha (min_samples_leaf)

controlam o equilíbrio entre viés e variância de cada árvore: árvores profundas têm baixo viés e alta variância e tendem a decorar o treino. No projeto testamos, com GridSearchCV (MAE, 5 dobras, só no treino), n_estimators em {200, 500}, max_depth em {None, 5, 10} e min_samples_leaf em {1, 2, 4}. O melhor foi 200, None e 1, a configuração mais flexível. Isso aparece no R^2 de treino de 0,991 contra 0,790 no teste (gap de 0,202, moderado). Mesmo assim, o R^2 de validação cruzada de 0,869 e o menor MAE de teste indicam que a flexibilidade não destruiu a generalização. Só testamos essa grade.

- **Pergunta:** *No caso do SVR, qual foi o critério para a escolha do Kernel (Linear, RBF, Polinomial)? Como essa escolha altera a dimensão do espaço de características onde o hiperplano de regressão é construído?*
    - **Resposta:** Incluímos os kernels linear e RBF no GridSearchCV (MAE, 5 dobras, só no treino), e o RBF foi o escolhido, com C = 300, epsilon = 0,1 e gamma = 0,01. Não testamos o kernel polinomial. O kernel linear trabalha no espaço original das variáveis. O RBF calcula, pelo truque do kernel, produtos internos em um espaço de características de dimensão infinita, onde o hiperplano de regressão é construído; no espaço original isso corresponde a uma função não linear. O gamma controla o alcance de cada ponto (gamma alto ajusta de forma muito local e favorece overfitting) e o C controla a penalização dos erros. O SVR foi o modelo com maior sinal de overfitting (R^2 de treino de 0,974 contra 0,587 no teste), e C = 300 foi o maior valor da grade, então o ótimo pode estar além dela.
- **Pergunta:** *Se a relação entre as variáveis fosse estritamente linear, o Random Forest ainda seria a melhor escolha? Justifiquem com base na complexidade do modelo.*
    - **Resposta:** Não necessariamente. Se a relação fosse estritamente linear, a Regressão Linear teria desempenho equivalente com menos complexidade, mais interpretabilidade, menor custo e menos risco de overfitting; pela Navalha de Ockham ela seria a escolha, e o Random Forest só acrescentaria complexidade (e ainda não extrapola). No nosso projeto, porém, há indícios de componentes não lineares: para carros comuns (sem o Land Cruiser), RFR e SVR erram cerca de 30% menos que a RLM em MAE (0,756 contra 1,073), e o MAPE do RFR é 16,1% contra 24,5% da RLM. Por outro lado, com o Land Cruiser no teste, o R^2 da RLM (0,799) é equivalente ao do RFR (0,790), e isso mostra que o conjunto de teste é frágil.

3. Eixo: Métrica e Interpretação de Performance

Fundamentação: Teoria da Estimação e Erro Quadrático vs. Erro Absoluto.

- **Pergunta:** *Observando o MAE e o RMSE, houve uma discrepância significativa entre eles? Se o RMSE for muito superior ao MAE, o que isso nos diz sobre a magnitude dos erros que o modelo está cometendo?*
    - **Resposta:** Sim, e ela varia entre os modelos. No teste, a razão RMSE/MAE é 1,87 na RLM (MAE 1,395 e RMSE 2,605), 2,37 no RFR (MAE 1,122 e RMSE 2,663) e 2,85 no SVR (MAE 1,309 e RMSE 3,733). O MAE é a média dos erros absolutos; o RMSE eleva os erros ao quadrado antes da média, então penaliza muito os erros grandes. Quando o RMSE é bem maior que o MAE, o erro está

concentrado em poucos casos grandes e não distribuído de forma uniforme. Confirmamos isso: um único carro, o Land Cruiser 2010, responde por 71,8% (RLM), 83,5% (RFR) e 94,0% (SVR) do erro quadrático total do teste. Sem ele, o RMSE cai para 1,402, 1,095 e 0,925. Ou seja, o erro típico é pequeno, mas os erros grandes na cauda de preços altos pesam muito.

- **Pergunta:** *O R² (Coeficiente de Determinação) foi alto, mas o modelo performou bem em dados de teste nunca vistos? Expliquem a importância da Validação Cruzada (Cross-Validation) para garantir que essas métricas sejam confiáveis.*
    - **Resposta:** Um R² alto no treino não garante generalização. O R² de treino foi 0,884 (RLM), 0,991 (RFR) e 0,974 (SVR), mas no teste ficou 0,799, 0,790 e 0,587. A validação cruzada reduz a dependência de uma única divisão treino/teste. Usamos GridSearchCV com 5 dobras, só no treino, para escolher os hiperparâmetros. Para medir a estabilidade, rodamos RepeatedKFold 5×3 sobre os 198 carros e obtivemos R² de CV de 0,823 ± 0,043 (RLM), 0,869 ± 0,066 (RFR) e 0,842 ± 0,150 (SVR). A limitação, que declaramos, é que as 40 linhas do teste entram nas dobras dessa validação cruzada, então o R² de CV pode ser levemente otimista. Por isso o conjunto de teste, separado do ajuste, é a nossa medida de generalização, e a validação cruzada é a medida de estabilidade. O desvio de 0,150 mostra que o SVR é instável.
- **Pergunta:** *Por que utilizamos o MAPE para explicar os resultados para um público não técnico (ex: diretoria de uma empresa) em vez de usar apenas o erro quadrático?*
    - **Resposta:** O MAPE (Mean Absolute Percentage Error) expressa o erro médio como percentual do valor real, o que um diretor entende sem conhecer a unidade (lakhs de rupias). O RFR tem MAPE de 16,1% no teste: em média erra cerca de 16% do preço, contra 24,5% da RLM e 17,0% do SVR. Métricas quadráticas, como o MSE, ficam em unidade ao quadrado e são menos intuitivas para uma apresentação gerencial. O MAPE tem limitações: infla o erro percentual de carros baratos (denominador pequeno) e não é definido quando o valor real é zero (no nosso caso o menor preço é 0,35 lakh). Por isso o apresentamos junto com o MAE, que na validação cruzada equivale a cerca de R$ 5.149 no RFR e R$ 7.451 na RLM (câmbio aproximado e conversão nominal).

4. Eixo: Tomada de Decisão e Recomendação

Fundamentação: Navalha de Ockham (Simplicidade vs. Performance).

- **Pergunta:** *Considerando que a Regressão Linear é muito mais simples e rápida de computar, o ganho de performance obtido com o Random Forest ou SVR justifica a perda de interpretabilidade do modelo?*
    - **Resposta:** Nos nossos resultados, o ganho do Random Forest é relevante em erro médio e percentual: MAE de teste de 1,122 contra 1,395 da RLM, MAPE de 16,1% contra 24,5% e MAE de validação cruzada de cerca de R$ 5.149 contra R$ 7.451. Para carros comuns, RFR e SVR erram cerca de 30% menos. Por outro lado, o R² de teste da RLM (0,799) é igual ao do RFR (0,790) e o RMSE dela é menor, e isso depende do Land Cruiser. Concluímos que o ganho justifica usar o RFR como apoio à precificação, mantendo a RLM como

baseline explicativo, porque ela mostra o peso de cada fator (como preço novo e idade). A interpretabilidade do RFR é parcial: a importância das variáveis (Present_Price 0,799, Car_Age 0,144, Kms_Driven 0,050) diz quais pesam, mas não a direção do efeito. Não recomendamos o SVR, pelo overfitting e pela instabilidade. Se a explicação for a prioridade da empresa, a RLM pode ser preferível.

- **Pergunta:** *Se este modelo fosse colocado em produção para prever dados em tempo real (milhares de requisições por segundo), qual algoritmo vocês recomendariam considerando o custo computacional de predição?*
  - **Resposta:** A RLM tem o menor custo por previsão: é uma combinação linear das variáveis de entrada, com custo proporcional ao número de variáveis e independente do tamanho do treino. O Random Forest precisa percorrer todas as árvores (200 no nosso caso) até uma folha, então o custo cresce com o número de árvores e a profundidade, embora as árvores possam rodar em paralelo. No SVR, o custo é proporcional ao número de vetores de suporte. **Não medimos os tempos de predição**, então não afirmamos números. Para milhares de requisições por segundo, recomendaríamos começar pela RLM, aceitando o erro maior (MAE de validação cruzada de R$ 7.451 contra R$ 5.149), ou medir o RFR, reduzindo número de árvores e profundidade, antes de decidir. Para o nosso dashboard, com poucas requisições, o custo não foi limitante na nossa observação.

Respostas curtas para a apresentação oral

Sobre os Kernels e o SVR (Domínio Teórico):

"Testamos os kernels linear e RBF e o RBF foi o escolhido. Ele projeta os dados, de forma implícita, em um espaço de dimensão infinita, o que permite modelar relações não lineares. O SVR e a Regressão Linear usaram StandardScaler porque, no SVR, o kernel depende de distâncias e a quilometragem dominaria o cálculo frente ao número de proprietários. Mesmo assim, o SVR teve o maior overfitting do projeto: R^2 de treino de 0,974 contra 0,587 no teste."

Sobre a Lógica de Ensemble do Random Forest (Domínio Teórico):

"O Random Forest usa bagging: cada árvore é treinada em uma amostra bootstrap e a previsão final é a média das 200 árvores, o que reduz a variância. As árvores dividem por limiares, não por distância, então são menos sensíveis a escala e a valores extremos nas entradas. O limite é que elas não extrapolam além do que viram no treino: o Land Cruiser, de 35 lakh, foi previsto em 19,60."

Sobre a Análise de Métricas (R^2, MAE, RMSE e MAPE):

"No teste, o Random Forest teve R^2 de 0,790, MAE de 1,122 lakh, MAPE de 16,1% e RMSE de 2,663; na validação cruzada, R^2 de 0,869. A RLM teve o melhor R^2 de teste (0,799), mas depende do Land Cruiser, que sozinho responde por 71,8% a 94,0% do erro quadrático. Por isso usamos o MAPE na apresentação executiva: o RFR erra, em média, cerca de 16% do preço, e o MAE de validação cruzada equivale a cerca de R$ 5.149."

Sobre a Defesa da Escolha e Produção:

> "Recomendamos o Random Forest como apoio à precificação e a Regressão Linear como baseline explicativo. Em produção com milhares de requisições por segundo, a RLM teria o menor custo por previsão; não medimos os tempos, então seria preciso medir o RFR antes de decidir. Para o nosso dashboard, o custo não foi um limitante."