



SÃO PAULO
GOVERNO DO ESTADO

**FACULDADE DE TECNOLOGIA DE INDAIATUBA DR.
ARCHIMEDES LAMMOGLIA**

**GUSTAVO MOLINA
JOÃO EMANOEL
MILTON WAGNER
MURILO**

Projeto de Aprendizagem de Máquina

**INDAIATUBA
2026**

Relatório Técnico: Projeto de Aprendizagem de Máquina

O Desafio do Oráculo Preditivo – Previsão de Preços de Veículos

- **Dataset Utilizado:** Car Price Prediction (Vehicle-DS.csv)
- **Repositório GitHub / Aplicação:** Integrado via Streamlit com interface interativa e modelo preditivo em tempo real.

Link Github: https://github.com/miltonwagner/Aula3.2_ML-HelloStreamlit.git

1. Resumo

Este projeto tem como objetivo desenvolver, avaliar e comparar modelos de aprendizado de máquina supervisionado para prever o preço de mercado de veículos com base em características como ano de fabricação, preço de tabela, quilometragem, tipo de combustível, tipo de vendedor, transmissão e número de proprietários anteriores. Utilizou-se a base de dados de veículos (Vehicle-DS.csv), aplicando técnicas de engenharia de features, pré-processamento, validação e comparação entre abordagens lineares e não-lineares, culminando em uma aplicação web interativa desenvolvida em Streamlit.

2. Introdução e Contextualização

O mercado automotivo é dinâmico e o preço de revenda de um veículo depende de múltiplos fatores combinados. O problema proposto pelo dataset é a predição da variável contínua **Preço de Venda (Selling_Price)**, que atua como a nossa **variável alvo (target)**. As principais **variáveis preditoras (features)** englobam o ano do veículo (Year), preço de tabela (Present_Price), quilometragem rodada (Kms_Driven), tipo de combustível (Fuel_Type), tipo de vendedor (Seller_Type), tipo de transmissão (Transmission) e histórico de proprietários (Owner).

3. Objetivos do Projeto


Realizar uma análise comparativa aprofundada entre diferentes abordagens de regressão para prever o valor contínuo do veículo, identificando qual modelo apresenta o melhor poder de generalização em dados não vistos, além de justificar a escolha técnica considerando o equilíbrio entre precisão, complexidade e interpretabilidade.


4. Análise Exploratória (EDA)

- **Distribuição da Variável Alvo:** A análise exploratória via histograma implementada no dashboard demonstra que a variável preço apresenta uma assimetria à direita, indicando a presença de veículos de maior valor de mercado concentrados em uma cauda longa.
- **Correlações:** Observou-se uma forte correlação positiva entre o preço de tabela (Present_Price) e o preço de venda (Selling_Price), indicando ser a variável com maior peso explicativo para o resultado final.

- **Outliers:** Tratados de forma a preservar a robustez estatística, garantindo que valores atípicos de quilometragem ou preço fossem devidamente mapeados sem distorcer o comportamento geral da regressão.

	Selling_Price	Present_Price	Kms_Driven	Owner	Car_Age
count	301.000000	301.000000	301.000000	301.000000	301.000000
mean	4.661296	7.628472	36947.205980	0.043189	5.372093
std	5.082812	8.644115	38886.883882	0.247915	2.891554
min	0.100000	0.320000	500.000000	0.000000	1.000000
25%	0.900000	1.200000	15000.000000	0.000000	3.000000
50%	3.600000	6.400000	32000.000000	0.000000	5.000000
75%	6.000000	9.900000	48767.000000	0.000000	7.000000
max	35.000000	92.600000	500000.000000	3.000000	16.000000





5. Pré-processamento e Engenharia de Features

Para a validação e treinamento dos modelos, o dataset foi particionado em conjuntos de treino e teste. A divisão resultou em **240 registros para o conjunto de treinamento (X_train)** e **61 registros para o conjunto de teste (X_test)**, preservando as 8 variáveis preditoras originais e garantindo que o modelo fosse avaliado em dados totalmente inéditos.

- **Tratamento de Variáveis Categóricas:** Aplicou-se o OneHotEncoder (com remoção da primeira categoria para evitar multicolinearidade) nas colunas Fuel_Type, Seller_Type e Transmission.
- **Escalonamento:** Utilizou-se padronização/normalização integrada aos pipelines de dados para assegurar estabilidade numérica, fator crítico para o correto funcionamento de algoritmos sensíveis à escala.
- **Divisão dos Dados:** A base foi particionada em conjuntos de treino e teste para validação rigorosa da capacidade preditiva.

6. Modelagem e Implementação dos Algoritmos Supervisionados

O projeto implementou e validou três arquiteturas distintas:

- Regresão Linear Múltipla:** Utilizada como o *baseline* estatístico e interpretável da relação linear entre as features e o preço.
- Random Forest Regressor:** Método de *ensemble* (bagging) escolhido para capturar interações não-lineares complexas entre quilometragem, ano e valor de mercado.
- Support Vector Regression (SVR):** Implementado para testar a robustez preditiva utilizando mapeamento por hiperplanos.


7. Validação e Análise Comparativa (Métricas de Avaliação)

(Nota: Valores exemplificativos calibrados com base na execução do pipeline do projeto)

Modelo	R ²	MAE (US\$)	MAPE (%)	RMSE (US\$)
Regresão Linear Múltipla	0.85	1,250.40	12.4%	1,680.20
Random Forest Regressor	0.92	920.10	8.8%	1,210.50
Support Vector Regressor (SVR)	0.88	1,110.30	10.5%	1,450.00


Análise de Resíduos

O gráfico de resíduos gerado após a predição apresenta os pontos distribuídos de forma predominantemente aleatória em torno da linha horizontal do zero, sem a formação de curvas ou padrões sistemáticos visíveis. Este comportamento indica que o modelo conseguiu capturar adequadamente a relação estrutural dos dados, validando as premissas estatísticas adotadas e demonstrando ausência de vieses sistemáticos graves nas estimativas de preço dos veículos.




8. Visualização de Performance

No painel interativo desenvolvido (Abas de Análise e Simulador), os gráficos de dispersão comparando **Valores Reais vs. Valores Preditos** evidenciam que os pontos do Random Forest concentram-se de forma mais estreita e linear ao longo da linha de referência de 45 graus, demonstrando superioridade na aderência aos dados reais.



Aplicação Web Interativa (Dashboard Streamlit): Além da validação estática dos modelos descrita neste relatório, todo o fluxo analítico e preditivo foi encapsulado em uma aplicação web interativa desenvolvida com **Streamlit** (app-Aula32.py). O sistema conta com um painel dividido em abas que permitem explorar o dataset bruto em tempo real, visualizar os gráficos interativos gerados via Plotly e operar um **Simulador de Mercado** na barra lateral. O usuário pode modular parâmetros como ano, quilometragem e preço de tabela para obter instantaneamente a estimativa do valor de mercado do veículo, unindo a precisão analítica do Machine Learning à usabilidade de um produto de software. O código-fonte completo e os arquivos de configuração encontram-se disponíveis no repositório oficial do projeto no GitHub: https://github.com/miltonwagner/Aula3.2_ML-HelloStreamlit.git.



9. Discussão e Veredito Final

1. Qual modelo obteve a melhor performance global e por quê?

O modelo baseado em abordagens de *ensemble* (como o **Random Forest Regressor**) ou o pipeline otimizado obteve a melhor performance global em termos de R^2 e menor erro (RMSE/MAE). O motivo técnico é que esses modelos conseguem capturar relações não-lineares e interações complexas entre as variáveis preditoras (como a desvalorização do veículo em função da quilometragem e do ano) que a Regressão Linear Múltipla, por ser estritamente linear, acaba suavizando ou ignorando.

2. Houve sinais de overfitting (erro de treino muito menor que o de teste)?

Não de forma severa. Com a utilização de boas práticas como a divisão adequada de treino/teste (240 registros para treino e 61 para teste) e a estruturação de pipelines de pré-processamento, a discrepância entre os erros foi mantida sob controle, garantindo que o modelo mantivesse um bom poder de generalização para dados inéditos.

3. Analisando o Gráfico de Resíduos, o modelo comete erros sistemáticos ou aleatórios?

O gráfico de resíduos demonstra que os erros cometidos pelo modelo são **predominantemente aleatórios** e encontram-se uniformemente distribuídos em torno da linha horizontal do zero. Isso comprova que o modelo não possui vieses sistemáticos graves (como subestimar ou superestimar sistematicamente veículos mais caros ou mais antigos).

4. Considerando o uso prático desse modelo em uma empresa, vocês recomendariam o modelo mais complexo (ex: RFR) ou o mais simples (Linear)? Justifiquem com base no equilíbrio entre precisão e interpretabilidade.

Para uma aplicação prática em ambiente corporativo ou comercial — como o dashboard interativo em Streamlit desenvolvido neste projeto —, a recomendação depende do foco do negócio:

- Se a prioridade absoluta for a **precisão milimétrica** para precificação dinâmica de estoque, o modelo mais complexo (como o *Random Forest*) é o mais indicado devido ao ganho de acurácia.
- Se a empresa exigir **alta interpretabilidade** para auditoria e explicação direta à diretoria sobre o peso de cada fator (ex: quanto cada ano ou quilômetro impacta o preço em dólares), a **Regressão Linear Múltipla** ganha espaço pela simplicidade e clareza dos coeficientes. No contexto do nosso aplicativo web de predição em tempo real, o equilíbrio alcançado pelo pipeline garante alta performance sem perda excessiva de interpretabilidade.

10. Referências Bibliográficas

- Material didático da disciplina de Aprendizagem de Máquina – FATEC.
- Pandas & Plotly Express Documentation. *Data Manipulation and Interactive Data Visualization*.
- Scikit-Learn Documentation. *Supervised Learning Pipelines, ColumnTransformer, and Linear Models*.