FACULDADE DE TECNOLOGIA DE INDAIATUBA DR. ARCHIMEDES LAMMOGLIA

GUSTAVO MOLINA
JOÃO EMANOEL
MILTON WAGNER
MURILO

Projeto de Aprendizagem de Máquina

INDAIATUBA
2026

Relatório Técnico: Projeto de Aprendizagem de Máquina

O Desafio do Oráculo Preditivo – Previsão de Preços de Veículos

Dataset utilizado: Car Price Prediction – CarDekho (arquivo Vehicle-DS.csv).

Aplicação: dashboard interativo em Streamlit (app-Aula32.py), com análise dos dados, comparação dos modelos e simulador de preço.

Repositório GitHub: https://github.com/miltonwagner/Aula3.2_ML-HelloStreamlit.git

1. Resumo

Este projeto desenvolve, avalia e compara três modelos de aprendizado de máquina supervisionado, a Regressão Linear Múltipla (RLM), o Random Forest Regressor (RFR) e o Support Vector Regression (SVR), para prever o preço de venda de carros usados a partir do preço do carro novo, da quilometragem, da idade, do número de proprietários anteriores, do combustível, do tipo de vendedor e da transmissão.

A base é a Car Price Prediction (CarDekho), arquivo Vehicle-DS.csv, com 301 linhas e 9 colunas. Após a limpeza (2 duplicatas removidas) e a separação das motos, restaram **198 carros**, usados nos modelos. Os preços estão em **lakhs de rupias** (1 lakh = ₹100.000). Os modelos foram avaliados com divisão treino/teste de 80/20 (158 e 40 carros), ajuste de hiperparâmetros por GridSearchCV (5 dobras) e validação cruzada repetida 5×3, usando R^2, MAE, MAPE e RMSE.

Não houve vencedor absoluto. A RLM teve o melhor R^2 de teste (0,799) e o menor RMSE (2,605). O RFR teve o menor MAE de teste (1,122 lakh), o menor MAPE (16,1%) e o maior R^2 de validação cruzada (0,869). O SVR teve o pior R^2 de teste (0,587) e o maior sinal de overfitting (gap de 0,387). Os erros grandes se concentram nos carros de preço alto: um único carro do teste, um Land Cruiser 2010, responde por 71,8% a 94,0% do erro quadrático dos três modelos. O projeto resulta também em um dashboard Streamlit com simulador.

2. Introdução e Contextualização

O mercado de carros usados é dinâmico, e o preço de revenda depende de vários fatores combinados, como o valor do carro novo, a idade, a quilometragem e as características do veículo. O problema proposto é a predição de uma variável contínua, o preço de venda (**Selling_Price**), que é a variável alvo (target).

As variáveis preditoras (features) do dataset são o ano do veículo (Year), o preço do carro novo (Present_Price), a quilometragem rodada (Kms_Driven), o tipo de combustível (Fuel_Type), o tipo de vendedor (Seller_Type), a transmissão (Transmission) e o número de proprietários anteriores (Owner). A partir do ano foi criada a variável Car_Age (idade do carro).

Dois cuidados sobre os dados orientam todo o relatório. Primeiro, os preços estão em **lakhs de rupias** e não em dólar. Segundo, os dados são de cerca de 2018, de modo que a conversão para dólar ou real pelo câmbio atual é apenas nominal. Além disso, o arquivo mistura carros e motos, e como o objetivo é a revenda de carros, os modelos usam somente os carros.

3. Objetivos do Projeto

O objetivo geral é realizar uma análise comparativa entre abordagens de regressão (linear, ensemble de árvores e vetores de suporte) para prever o preço de venda de carros usados, identificando qual modelo generaliza melhor para dados não vistos e justificando a escolha técnica pelo equilíbrio entre precisão, complexidade e interpretabilidade.

Os objetivos específicos são:

- realizar a análise exploratória e a auditoria de qualidade dos dados (duplicatas, inconsistências de texto, outliers, correlações e multicolinearidade);
- construir um pré-processamento sem vazamento de dados, com pipelines, codificação de variáveis categóricas e escalonamento quando necessário;
- ajustar hiperparâmetros com validação cruzada e comparar os modelos por R^2, MAE, MAPE e RMSE;
- analisar resíduos, overfitting e interpretabilidade para fundamentar a escolha do modelo;
- disponibilizar os resultados em um dashboard Streamlit com simulador de preço.

4. Análise Exploratória dos Dados (EDA)

4.1 Qualidade e limpeza dos dados

O arquivo bruto tem 301 linhas e 9 colunas (Car_Name, Year, Selling_Price, Present_Price, Kms_Driven, Fuel_Type, Seller_Type, Transmission, Owner), sem valores nulos e com **2 duplicatas exatas** (Ertiga 2016 e Fortuner 2015), removidas. Na coluna Car_Name havia 6 nomes com espaço duplo, 5 com espaços nas bordas e 101 com maiúsculas misturadas, todos padronizados (strip, colapso de espaços e minúsculas). Restaram 299 linhas.

4.2 Carros e motos

O arquivo mistura **198 carros e 101 motos**. A diferença de preço é grande: o preço médio de venda é de 6,60 lakh para carros e 0,64 lakh para motos. Por isso, os modelos usam apenas os carros. O tipo do veículo foi definido por uma expressão regular de marcas de moto no início do nome (bajaj, hero, honda, yamaha, tvs, ktm, royal, hyosung, mahindra, suzuki, um e activa). Essa heurística **não foi validada linha a linha**.

Entre os carros, o vendedor é Dealer em 193 casos e Individual em apenas 5; o combustível é Petrol em 138, Diesel em 58 e CNG em 2; a transmissão é Manual em 168 e Automatic em 30. As categorias com poucos exemplos (CNG e Individual) limitam o que se pode concluir sobre elas.

Tabela 1 – Preços médios convertidos (1 lakh = US$ 1,053 = R$ 5,480)

Indicador (valores em lakh e convertidos)	Lakh	US$	R$
Carro, preço novo médio	10,88	11.455,34	59.636,52
Carro, preço de venda médio	6,60	6.951,52	36.189,59
Moto, preço de venda médio	0,64	674,52	3.511,54
Maior preço de venda	35,00	36.842,11	191.800,00

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

Como os preços do dataset são de cerca de 2018, a conversão pelo câmbio atual é apenas nominal.

4.3 Distribuição da variável alvo

Entre os carros, o preço de venda tem média de 6,60 lakh, desvio padrão de 5,04, mínimo de 0,35, primeiro quartil de 3,61, mediana de 5,25, terceiro quartil de 7,50 e máximo de 35,00. A média acima da mediana e a assimetria (skew) de 2,7 indicam uma **cauda longa à direita**. Por isso o histograma também foi feito em escala log1p.

Tabela 2 – Estatísticas descritivas dos 198 carros

Variável (carros)	Média	Mediana	Máximo
Selling_Price (lakh)	6,60	5,25	35,00
Present_Price (lakh)	10,88	8,45	92,60
Kms_Driven (km)	41.403,92	39.742,50	197.176
Owner	0,04	0	3
Car_Age (anos)	5,43	5	16

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

A variável Owner é quase constante (mediana 0), com pouco poder para discriminar preços. A idade (Car_Age = 2019 − Year) varia de 1 a 16 anos.

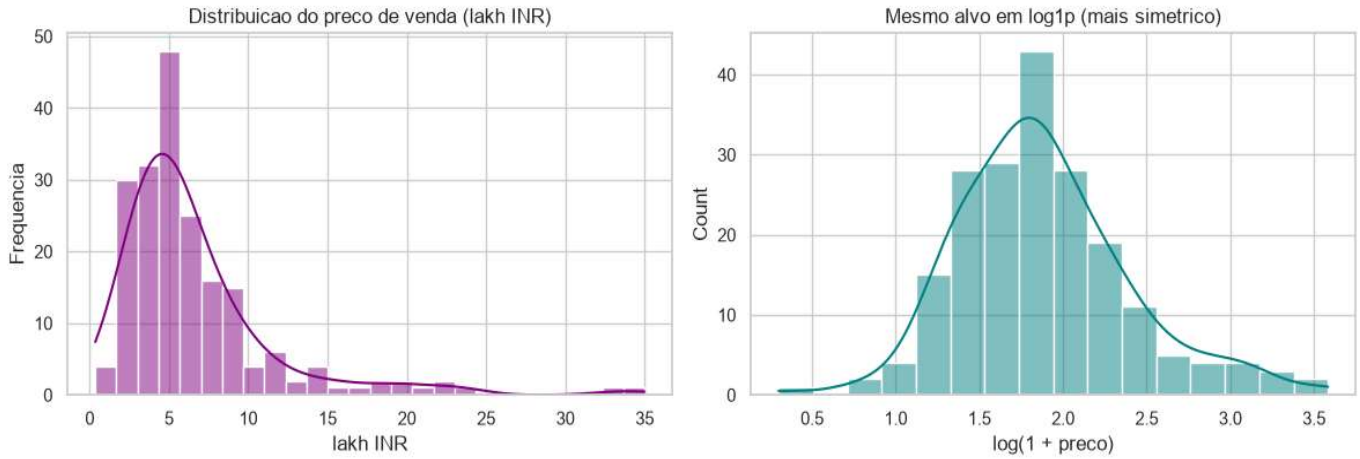


Figura 1 – Distribuição do preço de venda dos carros (escala original e log1p)

4.4 Outliers

Pela regra de 1,5 × IQR, há 16 outliers em Selling_Price, 11 em Present_Price e 6 em Kms_Driven, todos na cauda superior.

Tabela 3 – Outliers pela regra de 1,5 × IQR (carros)

Variável	Nº de outliers	Limite superior (≈)
Selling_Price	16	13,34 lakh
Present_Price	11	24,02 lakh
Kms_Driven	6	101.107 km

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

Decisão: manter os outliers. São carros reais e caros, como o Land Cruiser 2010 (novo a 92,60 e vendido a 35,00 lakh) e os Fortuner 2017 e 2014. Removê-los eliminaria justamente os carros de maior valor e deixaria o modelo cego para essa faixa. O efeito dessa decisão é analisado na seção 7.2.

4.5 Correlações e multicolinearidade

Em relação ao preço de venda, a correlação mais forte é com o preço do carro novo (**+0,82**). A idade tem correlação de −0,35, a quilometragem de −0,11 e o número de proprietários de −0,08. Entre as variáveis preditoras, a maior correlação é entre quilometragem e idade (+0,71), seguida de quilometragem e preço novo (+0,25) e quilometragem e proprietários (+0,20).

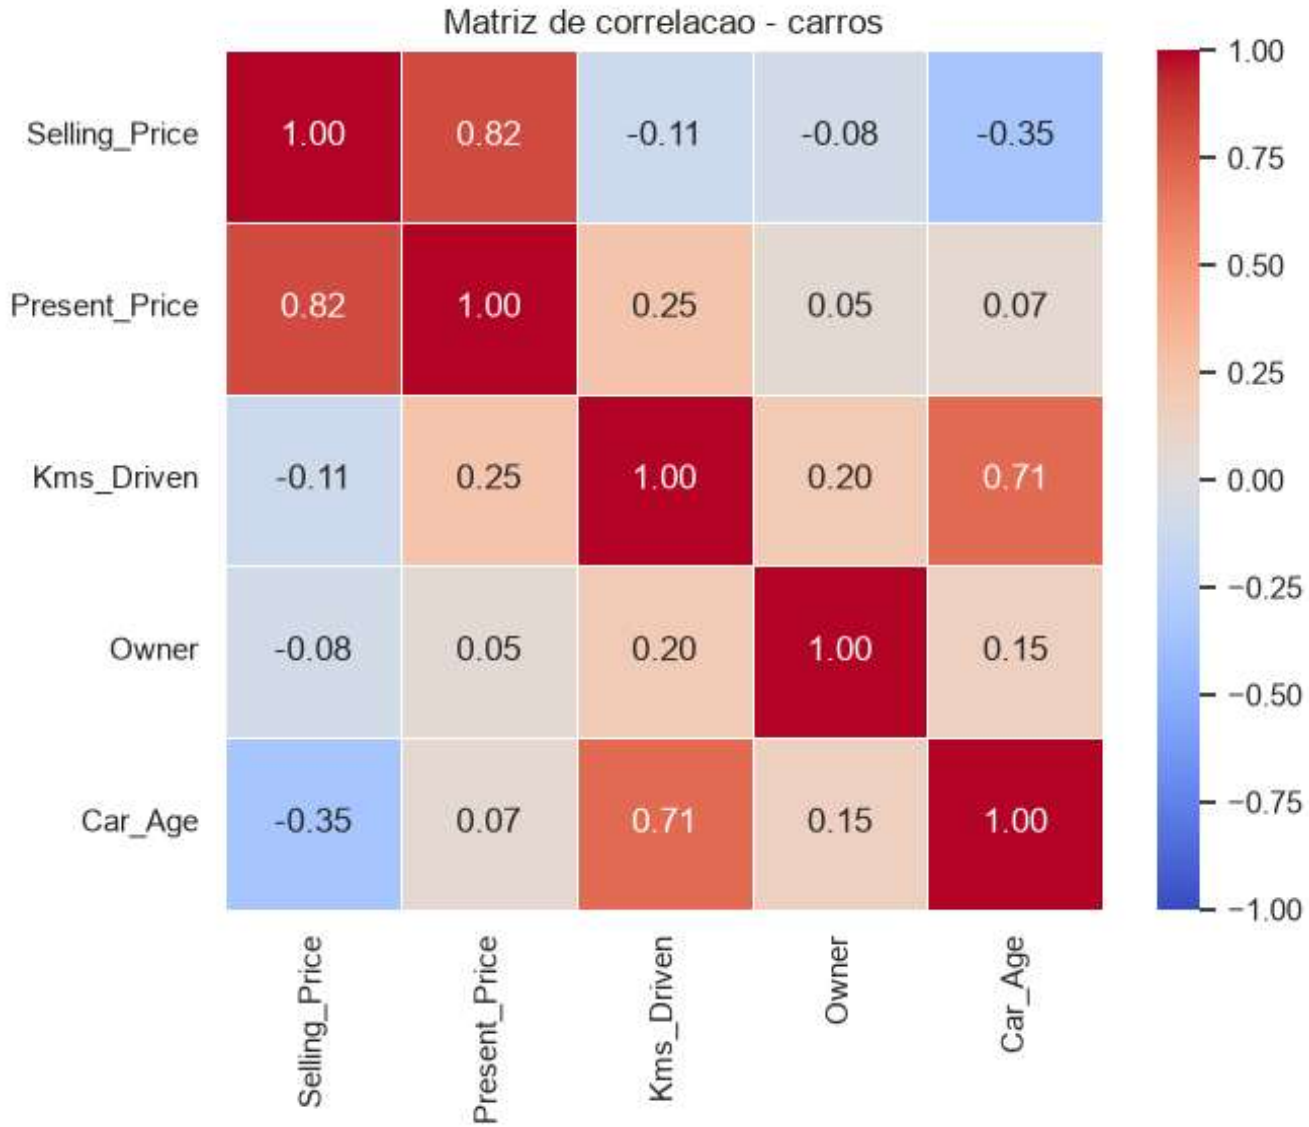


Figura 2 – Matriz de correlação das variáveis numéricas dos carros

Para verificar multicolinearidade foi calculado o fator de inflação da variância (VIF) das quatro variáveis numéricas (as dummies não entraram no cálculo). Todos os valores ficaram abaixo de 2,3, longe dos limites usuais de preocupação, portanto **não há multicolinearidade problemática**.

Tabela 4 – Fator de inflação da variância (VIF) das variáveis numéricas

Variável	VIF	Leitura
Present_Price	1,10	sem problema
Kms_Driven	2,23	sem problema
Owner	1,04	sem problema
Car_Age	2,07	sem problema

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

4.6 Depreciação

A retenção de valor (preço de venda dividido pelo preço novo) cai com a idade do carro. A tabela mostra a mediana por idade. As pontas, com 1 ano e de 11 a 16 anos, têm poucos carros (1 a 3) e **não são conclusivas**.

Tabela 5 – Retenção mediana de valor por idade (carros)

Idade (anos)	Retenção mediana	Nº de carros
1	0,94	1
2	0,91	19
3	0,78	30
4	0,72	45
5	0,63	28
6	0,54	20
7	0,48	16
8	0,48	13
9	0,36	10
10	0,30	5
11	0,22	2
13	0,25	3
14	0,26	3
15	0,12	1
16	0,22	2

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

Por combustível, a retenção mediana é 0,67 para Diesel (58 carros) e 0,64 para Petrol (138); o CNG (0,51) tem apenas 2 carros e não é interpretável. Por transmissão, é 0,70 para Automatic (30) e 0,65 para Manual (168).

5. Pré-processamento e Engenharia de Features

5.1 Seleção e limpeza

Foram removidas as duplicatas, os nomes foram padronizados e os modelos foram treinados apenas com os 198 carros (seção 4).

5.2 Engenharia de features

Foi criada a variável **Car_Age = 2019 − Year**, a idade do carro na época da coleta (o último ano do dataset é 2018). As variáveis numéricas usadas são Present_Price, Kms_Driven, Owner e Car_Age, e as categóricas são Fuel_Type, Seller_Type e Transmission.

5.3 Variáveis categóricas

Foi aplicado o OneHotEncoder com **drop="first"** (remove uma categoria de referência para evitar a armadilha das variáveis dummy) e handle_unknown="ignore". A categoria de referência de combustível é o CNG, que tem só 2 carros; por isso os coeficientes de Diesel e Petrol, que são relativos a ele, não são interpretáveis (seção 7.4).

5.4 Escalonamento

O StandardScaler foi aplicado **apenas à RLM e ao SVR**, dentro do Pipeline, de modo que a média e o desvio padrão são calculados somente nos dados de treino e não há vazamento. O SVR com kernel RBF depende de distâncias e fica distorcido quando as variáveis têm escalas muito diferentes (por exemplo, quilometragem na casa das dezenas de milhares e Owner entre 0 e 3). O Random Forest, baseado em divisões por limiar, não precisa de escala.

5.5 Divisão treino e teste

Os 198 carros foram divididos em 80% para treino (**158 carros**) e 20% para teste (**40 carros**), com random_state=42. O conjunto de teste fica de fora de todo o ajuste de hiperparâmetros.

5.6 Hiperparâmetros e validação cruzada

Os hiperparâmetros foram ajustados com **GridSearchCV de 5 dobras, usando o MAE como métrica, apenas no conjunto de treino**.

Tabela 6 – Grades de hiperparâmetros e melhores valores

Modelo	Hiperparâmetro	Valores testados	Melhor
RFR	n_estimators	200; 500	200
RFR	max_depth	None; 5; 10	None
RFR	min_samples_leaf	1; 2; 4	1
SVR	kernel	rbf; linear	rbf
SVR	C	1; 10; 100; 300	300
SVR	epsilon	0,05; 0,1; 0,5	0,1
SVR	gamma	scale; 0,01; 0,1	0,01
RLM	(sem hiperparâmetros ajustados)	–	–

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

Duas observações. O valor C = 300 é o **maior** da grade, então o ótimo pode estar além dela. E o RFR escolheu as opções mais flexíveis (sem limite de profundidade e folhas de 1 amostra), o que ajuda a explicar o seu R^2 de treino de 0,991.

Para medir a estabilidade, foi feita validação cruzada **RepeatedKFold 5×3** (random_state=42) sobre os 198 carros, com os hiperparâmetros já escolhidos no treino. **Limitação:** as 40 linhas de teste entram nas dobras dessa validação cruzada, então o R^2 de

CV pode ser levemente otimista. A validação cruzada mede a estabilidade; o teste, que ficou fora do ajuste, mede a generalização.

5.7 Modelagem dos três algoritmos

Regressão Linear Múltipla (RLM). Baseline estatístico e interpretável, que assume relação linear entre as variáveis (já padronizadas) e o preço.

Random Forest Regressor (RFR). Ensemble de árvores (bagging) com 200 árvores, sem limite de profundidade e com folhas de 1 amostra. Captura relações não lineares e interações, e não precisa de escalonamento.

Support Vector Regression (SVR). Regressão por vetores de suporte, com kernel RBF, C = 300, epsilon = 0,1 e gamma = 0,01, aplicada sobre as variáveis padronizadas.

6. Validação e Análise Comparativa

Todas as métricas de erro estão em lakh de rupias. As métricas de teste foram calculadas nos 40 carros reservados.

Tabela 7 – Métricas no conjunto de teste (40 carros; erros em lakh)

Modelo	R^2	MAE	MAPE (%)	RMSE
Regressão Linear Múltipla	0,799	1,395	24,470	2,605
Random Forest Regressor	0,790	1,122	16,081	2,663
SVR	0,587	1,309	16,971	3,733

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

Tabela 8 – Treino, validação cruzada (5×3) e overfitting

Modelo	R^2 treino	R^2 CV (média ± desvio)	MAE CV	Gap (treino − teste)
RLM	0,884	0,823 ± 0,043	1,360	0,085
RFR	0,991	0,869 ± 0,066	0,940	0,202
SVR	0,974	0,842 ± 0,150	0,918	0,387

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

A leitura das tabelas mostra três coisas. A RLM tem o melhor R^2 e o menor RMSE de teste. O RFR tem o menor MAE e o menor MAPE de teste e o maior R^2 de validação cruzada. O SVR tem o menor MAE de validação cruzada (0,918), mas o pior desempenho no teste e a maior instabilidade entre as dobras (desvio de 0,150).

Para dar uma ideia do tamanho do erro em moeda, o MAE de validação cruzada, convertido, equivale a cerca de R$ 7.451 para a RLM, R$ 5.149 para o RFR e R$ 5.030 para o SVR (câmbio aproximado e conversão nominal).

Tabela 9 – MAE da validação cruzada convertido

Modelo	MAE CV (lakh)	₹	US$	R$
RLM	1,36	135.967,78	1.431,24	7.451,03
RFR	0,94	93.958,02	989,03	5.148,90
SVR	0,92	91.793,42	966,25	5.030,28

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

7. Critérios de Escolha

7.1 Análise de resíduos

Para a maioria dos carros do teste, os resíduos (real − previsto) são pequenos e com aparência aleatória em torno de zero. Pelos gráficos, a RLM fica em torno de ±4 lakh, o RFR dentro de cerca de ±3,5 e o SVR em cerca de ±2 (valores ≈ lidos dos gráficos). Na cauda de preços altos, porém, o erro é **sistemático**: a RLM superestima o carro mais caro e o RFR e o SVR o subestimam.

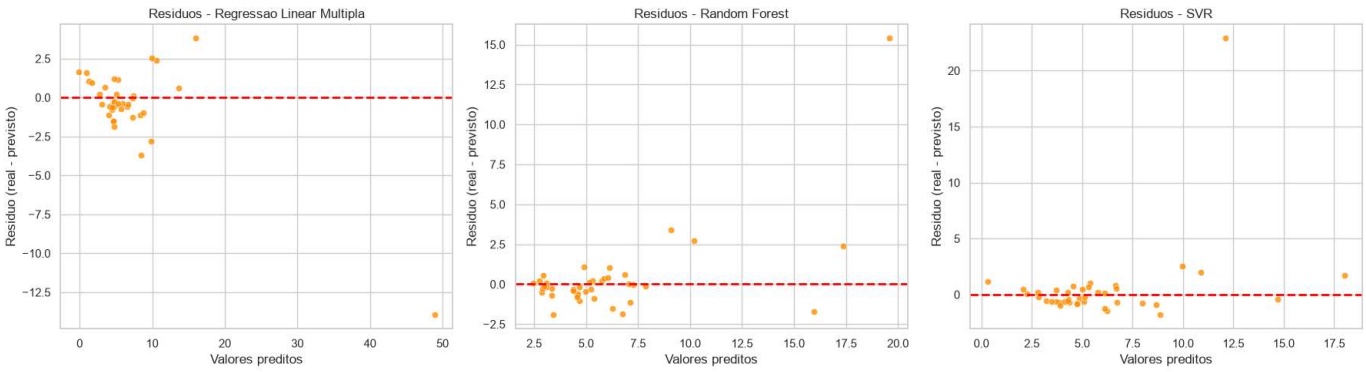


Figura 3 – Resíduos (real − previsto) dos três modelos no conjunto de teste

A explicação mais provável é que a RLM extrapola em linha reta, enquanto as árvores do RFR não extrapolam além do que viram no treino. Essa é uma **hipótese não testada**. Além disso, a RLM previu um preço negativo no teste (−0,17 lakh), o que é impossível.

7.2 Sensibilidade ao carro mais caro do teste

O carro de maior preço do teste é um **Land Cruiser 2010** (preço novo de 92,6 lakh e preço de venda de 35,0 lakh). Ele sozinho concentra a maior parte do erro quadrático dos três modelos. A tabela mostra o que acontece quando ele é retirado do cálculo das métricas (análise pós-hoc, que não substitui as métricas oficiais da seção 6).

Tabela 10 – Sensibilidade das métricas de teste ao Land Cruiser 2010 (real = 35,0 lakh)

Modelo	Previsto	Resíduo	% do erro quad.	R^2 sem ele	MAE sem ele	RMSE sem ele
RLM	48,96	−13,96	71,8%	0,849	1,073	1,402
RFR	19,60	+15,40	83,5%	0,908	0,756	1,095
SVR	12,11	+22,89	94,0%	0,934	0,756	0,925

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

O ranking de R^2 de teste se **inverte** sem esse carro: com ele a ordem é RLM > RFR > SVR, e sem ele é SVR > RFR > RLM. Para carros comuns, RFR e SVR erram cerca de 30% menos que a RLM (MAE de 0,756 contra 1,073). Isso mostra que o conjunto de teste de 40 carros é frágil, e por isso a comparação deve se apoiar também na validação cruzada, no MAE e no MAPE.

A razão RMSE/MAE no teste é de 1,87 para a RLM, 2,37 para o RFR e 2,85 para o SVR. Quanto maior a razão, mais o erro está concentrado em poucos casos grandes, o que é coerente com o efeito do Land Cruiser.

7.3 Overfitting

Medido pela diferença entre o R^2 de treino e o R^2 de teste, o overfitting é **leve na RLM** (gap de 0,085), **moderado no RFR** (0,202) e **forte no SVR** (0,387). No RFR, o gap é típico de árvores sem limite de profundidade e com folhas de 1 amostra, mas o modelo ainda tem o maior R^2 de validação cruzada (0,869) e o menor MAE de teste. No SVR, o R^2 de treino de 0,974 contra 0,587 no teste indica que o modelo decorou o treino e generalizou mal, ainda que o seu desempenho na validação cruzada seja razoável.

7.4 Interpretabilidade

Na RLM, os coeficientes das variáveis numéricas (padronizadas) indicam quanto o preço muda, em lakh, para uma variação de um desvio padrão da variável, mantidas as demais constantes. O intercepto é 6,324.

Tabela 11 – Coeficientes da regressão linear múltipla

Variável (RLM)	Coeficiente	Interpretável?
Present_Price	+3,757	sim
Car_Age	−1,182	sim
Kms_Driven	−1,158	sim
Owner	−0,418	com cautela
Transmission_Manual	−0,637	com cautela
Fuel_Type_Petrol	+0,295	não (relativo ao CNG, 2 carros)
Fuel_Type_Diesel	+2,088	não (relativo ao CNG, 2 carros)
Seller_Type_Individual	+2,075	não (apenas 5 carros)

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

Na RLM, a quilometragem tem efeito grande (−1,158) apesar da correlação simples de apenas −0,11. Isso ocorre porque o modelo controla o efeito do preço novo e da idade, que são correlacionados com a quilometragem. Já no RFR, a quilometragem tem importância pequena (0,050). Por isso é preciso sempre citar de qual modelo vem cada leitura.

Tabela 12 – Importância das variáveis no Random Forest

Variável (RFR)	Importância	Leitura
Present_Price	0,799	dominante
Car_Age	0,144	relevante
Kms_Driven	0,050	pequena
Fuel_Type_Diesel	0,002	desprezível
Fuel_Type_Petrol	0,002	desprezível
Transmission_Manual	0,001	desprezível
Seller_Type_Individual	0,000	desprezível
Owner	0,000	desprezível

Fonte: elaborado pelos autores a partir da execução do notebook analise_veiculos.ipynb.

A importância por impureza favorece variáveis contínuas e divide o crédito entre variáveis correlacionadas, então deve ser lida com cautela. Ainda assim, os dois modelos concordam no essencial: o preço do carro novo é, de longe, o fator mais importante, seguido da idade.

8. Visualização de Performance

Os gráficos de valores reais contra valores preditos, com a linha de 45° como referência de previsão perfeita, mostram que até cerca de 15 lakh os três modelos ficam próximos da diagonal. A partir daí o erro cresce. Para um carro de cerca de 20 lakh, a previsão fica em torno de 16 (RLM), 17 (RFR) e 18 (SVR). Para o Land Cruiser (real 35 lakh), a previsão é de 48,96 (RLM), 19,60 (RFR) e 12,11 (SVR). Nenhum modelo é confiável acima de cerca de 15 a 20 lakh.

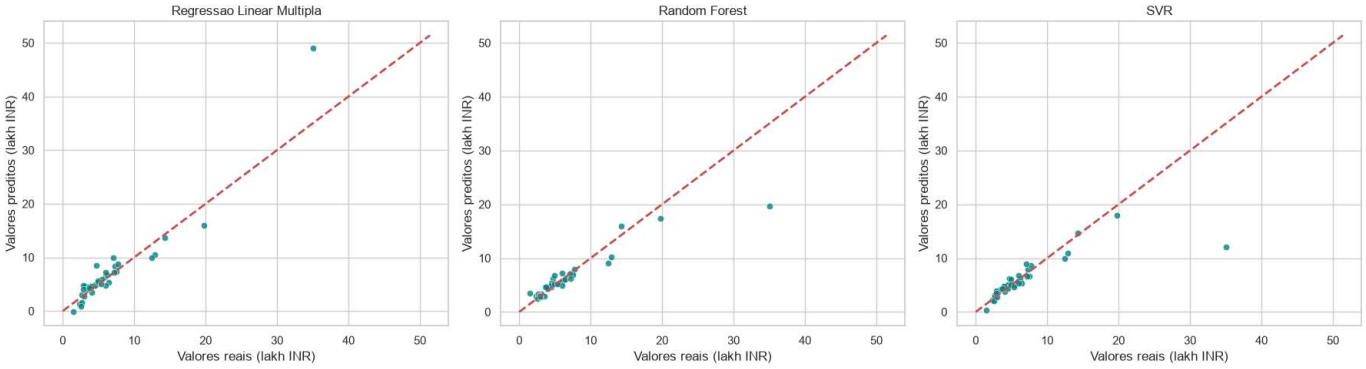


Figura 4 – Valores reais × valores preditos no conjunto de teste (40 carros), com linha de 45°

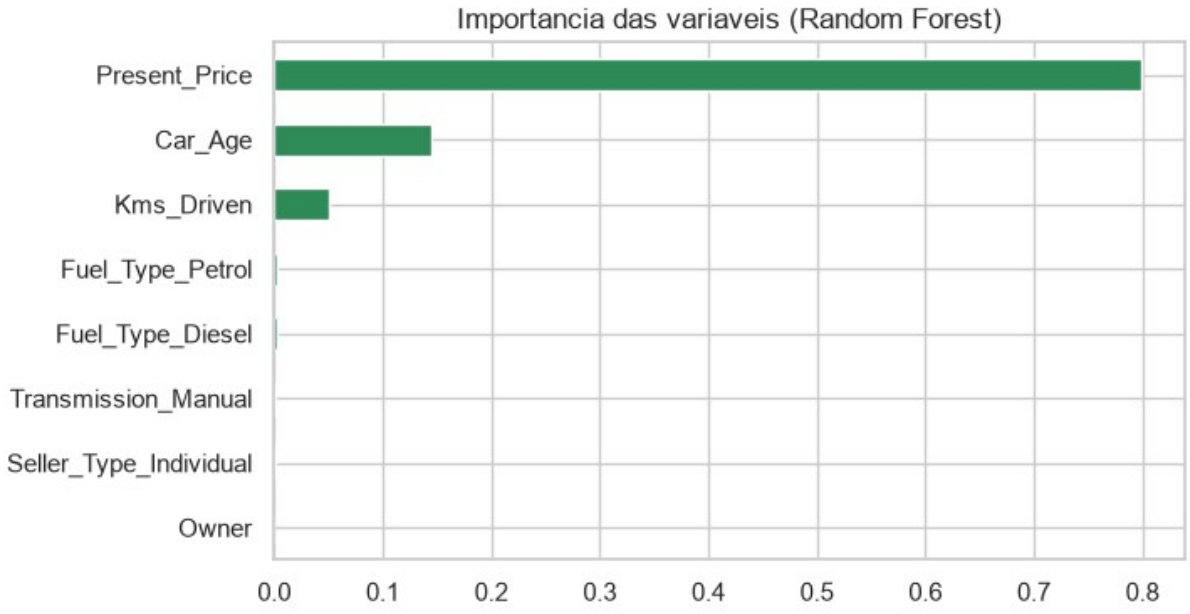


Figura 5 – Importância das variáveis no Random Forest

Aplicação web interativa (dashboard Streamlit)

Todo o fluxo foi encapsulado em um dashboard Streamlit (app-Aula32.py), com cinco abas: (1) dados e qualidade, com a auditoria da limpeza e a separação entre carros e motos; (2) análise exploratória, com histograma, dispersão, boxplots, matriz de correlação e depreciação; (3) modelos, com a tabela de métricas, os gráficos de reais contra preditos e de resíduos, a análise de sensibilidade, os coeficientes da RLM e a importância do RFR; (4) simulador, em que o usuário informa as características do carro e recebe a estimativa dos três modelos lado a lado; e (5) valores convertidos para rupias, dólares e reais, com câmbio editável na barra lateral.

O simulador avisa quando os valores informados estão fora da faixa vista no treino e limita previsões negativas a zero. O código e os arquivos de configuração estão no repositório do projeto: https://github.com/miltonwagner/Aula3.2_ML-HelloStreamlit.git.

9. Discussão e Veredito Final

1. Qual modelo obteve a melhor performance global e por quê?

Não há um vencedor absoluto. A RLM é melhor em R^2 de teste (0,799) e em RMSE (2,605) e é a mais estável, mas esse resultado depende do Land Cruiser: sem ele, a RLM passa a ter o pior desempenho dos três. O RFR é melhor em MAE de teste (1,122 lakh), em MAPE (16,1%) e em R^2 de validação cruzada (0,869). O SVR tem o menor MAE de validação cruzada (0,918), mas o pior R^2 e RMSE de teste e a maior instabilidade. Para carros comuns, o RFR e o SVR erram cerca de 30% menos que a RLM, o que sugere que a relação entre as variáveis tem componentes não lineares que a RLM não captura.

2. Houve sinais de overfitting?

Sim, em graus diferentes: leve na RLM (gap de 0,085), moderado no RFR (0,202) e forte no SVR (0,387). O overfitting do SVR é o principal motivo para não recomendá-lo.

3. Os resíduos mostram erros sistemáticos ou aleatórios?

Para a maioria dos carros, os erros são pequenos e aleatórios. Na cauda de preços altos, os erros são sistemáticos: a RLM superestima o carro mais caro do teste e o RFR e o SVR o subestimam.

4. Modelo complexo ou simples: o que recomendar?

Recomendamos o **Random Forest como apoio à precificação**, e a **RLM como modelo de referência explicativo**. O RFR erra menos em termos absolutos e percentuais: MAE de validação cruzada de cerca de R$ 5.149 contra R$ 7.451 da RLM, e MAPE de teste de 16,1% contra 24,5%. Em termos práticos, para um público não técnico, o erro médio do RFR é de cerca de 16% do preço. A RLM continua útil para explicar à diretoria o peso de cada fator (por exemplo, preço novo e idade), mas não deve ser apresentada como equivalente ao RFR para carros comuns. Pelo princípio da simplicidade (Navalha de Ockham), a RLM seria preferível se a precisão fosse parecida, o que não ocorre aqui. Não recomendamos o SVR, pelo overfitting e pela instabilidade. O custo de predição do RFR (200 árvores) é maior que o da RLM, mas não foi medido neste trabalho.

Limitações

- Poucos dados: apenas 198 carros, e um conjunto de teste de 40 carros, que é frágil (um único carro muda o ranking).
- Os preços são de cerca de 2018 e a conversão para dólar e real é apenas nominal.
- Nenhum modelo é confiável acima de cerca de 15 a 20 lakh. A RLM pode prever preço negativo e o RFR não extrapola além do treino.
- A validação cruzada foi feita sobre os 198 carros, incluindo as linhas de teste, e pode ser levemente otimista.
- A separação entre carros e motos usa uma heurística por nome, não validada linha a linha.
- As categorias CNG e vendedor Individual têm pouquíssimos carros, então seus efeitos não são interpretáveis.

10. Referências Bibliográficas

- Car Price Prediction (CarDekho), arquivo Vehicle-DS.csv.
- Material didático da disciplina de Aprendizagem de Máquina – FATEC Indaiatuba
- Pandas Documentation. Data manipulation. Disponível em: https://pandas.pydata.org.
- Plotly Express Documentation. Interactive data visualization. Disponível em: https://plotly.com/python/plotly-express/.
- Scikit-Learn Documentation. Supervised learning, pipelines, ColumnTransformer, model selection and metrics. Disponível em: https://scikit-learn.org.
- Streamlit Documentation. Disponível em: https://docs.streamlit.io.